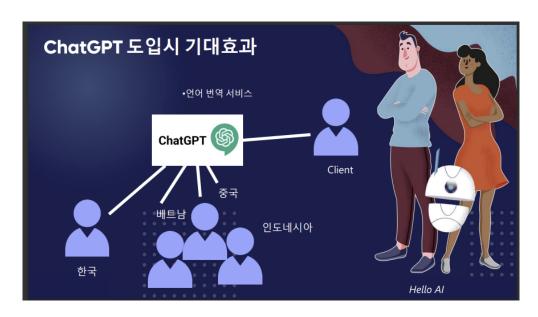
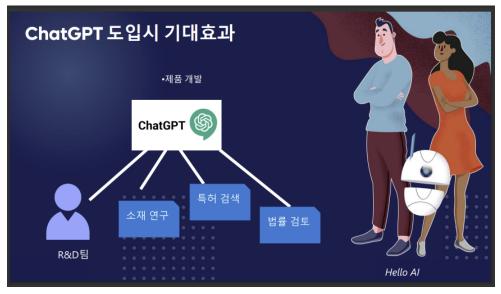
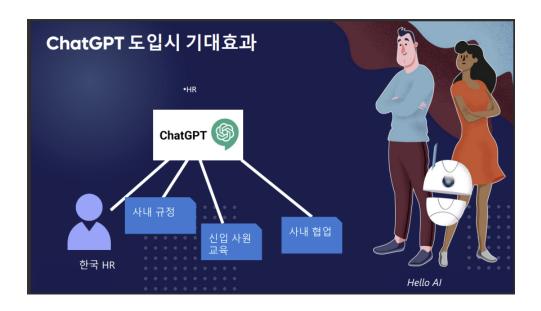
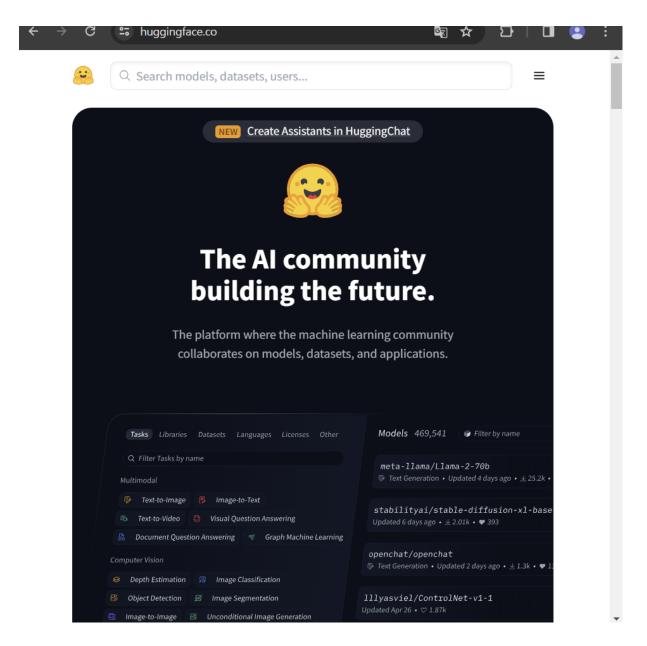
오늘은 Langchain을 통해서 문서 분할, 임베딩, — 할 것



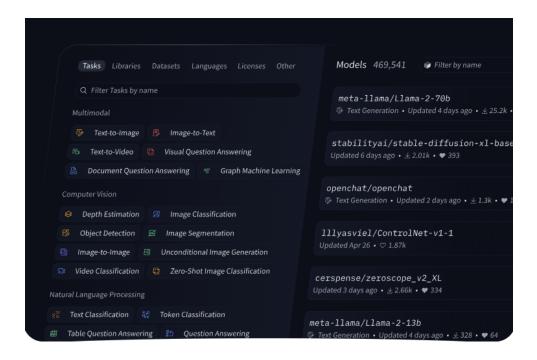




<Hugging face>



- 언어 모델계의 깃허브 새로운 모델이 나오면 여기 다 올라옴
- 언어 모델 뿐만 아니라 AI 모델도 많이 올라와 있음



- Multimodal: 두 가지 이상의 모델을 함께 사용하는 것. ex) GPT
- Meta-llama-2-70b: 70 billion의 파라미터
- 암튼 이렇게 공개된 모델을 다운받아 튜닝할 수도 있음
- 오픈소스 모델인데도 한국어 지원됨
- LangCon...

<LangChain>

https://colab.research.google.com/drive/1Zk4c4Yomu86KgUEla1J1NOF6J0wr6jyW?usp=sharing

pdf 파일을 준비하자

https://onedrive.live.com/redir?

resid=E04DC3BEC3161F8B!443813&authkey=!AKnTCh0F5UEh-

og&page=View&wd=target(Class Room.one 50f7877f-d674-46e1-a7e2-

25db0cd73579%2F00. 시작하기 1e48b674-7832-c845-8992-

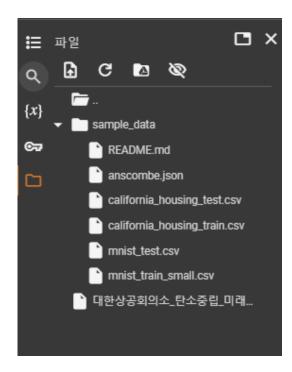
5cb3b21bb7bb%2F)&wdorigin=NavigationUrl

<대한상공회의소_탄소중립_미래전략_보고서_Part1>

그리고 새로운 코랩 노트 열자

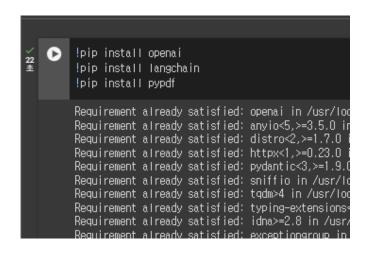


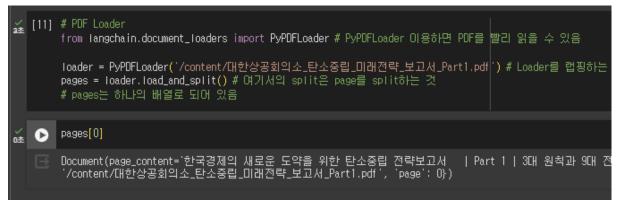
pdf 파일을 업로드해서 테스트해보자



```
**PF Loader** | PFOFLoader** | PFOFL
```

• 오류가 나는 이유는 install pypdf가 없어서





- 이제 잘 됨 & pages[0]하면 첫 번째 페이지가 출력됨
- return되는 결과가 document. 실제 내용은 page_content에 있음
- 그 안의 내용을 가져오고 싶으면 .page_content



• 이렇게 내용이 나옴

<두 번째... >

Max Token = 글자 수와 상관 없이 토큰 단위로 한계가 설정되어 있음 페이지 단위로 자르는데 어떤 페이지는 1500자, 어떤 페이지는 2000자 근데 그게 중요한 게 아님. 토큰 수가 중요! 토큰 수가 Max Token 넘어가면 잘라줘야 함한 페이지이지만 내부적으로는 두 개의 블록이 될 수도 있다는 것

- 1. 토큰 단위로 페이지 세기
- 2. 토큰 단위로 페이지 쪼개기

를 해보자

<쪼개자>

내용을 자를 땐 두 가지 splitter. CharacterTextSplitter와 RecursiveCharacterTextSplitter

- 첫 번째 CharacterTextSplitter: 주어진 단위대로 자르고 넘치면 버림
- 두 번째 RecursiveCharacterTextSplitter: 한 페이지가 넘치면 다시 돌아와 남은 부분을 다시 쪼갬. 그래서 필요한 단위로 쪼개질 때까지 재귀호출... 그래서 이걸 많이 사용함

```
[16] # split
      from langchain_text_splitters import CharacterTextSplitter
      from langchain_text_splitters import RecursiveCharacterTextSplitter
      # 내용을 자를 땐 두 가지 splitter. CharacterTextSplitter와 RecursiveCharacterTextSplitter
      text_splitter = CharacterTextSplitter(
         separator = '\n',
         chunk_size = 100, # 100자 단위로 잘라서 페이지를 쪼갬
         chunk_overlap = 10, # 10자씩 겹침(?)
         length_function = len
[17] texts = text_splitter.split_text(pages[45].page_content)
 ▶ print(texts[0]) # 0번 문단 print
      print('-'*100)
      print(texts[1]) # 1번 문단 print
      print('-'*100)
     print(texts[2]) # 2번 문단 print
 ☐ 46 | 47
The Korea Chamber of Commerce & Industry제고될 것으로 기대된다. 또한 재생에너지 확대에 따른 전력 계통의 안정적
      운영에도 긍정적 영향을 미칠 것으로 예상된다. 우선 장단기 계약에서 실시간
시장에 미르기까지 다양한 전력시장의 구축으로 물량과 가격의 위험성을
      완화할 수 있다. 이와 함께 재생에너지의 변동성을 반영하는 실시간 가격기능의
작동으로 수용성이 커질 뿐만 아니라 공급여력이 부족할 때 시장가치를
```

- 쪼갤 때 사용 가능한 속성들들
 - splitter: 자르는 기준. 뭘 기준으로 자를 건지.
 - o chunk: 자르는 단위(의 사이즈)
 - chunk_overlap: 자를 때 칼같이 자르면 연결고리가 없어지니까 살짝 overlap 시켜놓는
 것

각 문단의 size를 보기 위해 list를 만들어보자

```
# split
from langchain_text_splitters import CharacterTextSplitter
from langchain_text_splitters import RecursiveCharacterTextSplitter
# 내용을 자를 땐 두 가지 splitter. CharacterTextSplitter와 Recursive
text_splitter = CharacterTextSplitter()
separator = '\m',
chunk_size = 50, # 100자 단위로 잘라서 페이지를 쪼갬
chunk_overlap = 5, # 10자씩 겹침(?)
length_function = len
```

일단 숫자 좀 바꾸고

글자가 넘쳐서 잘려나감 & page 수 늘어남 엥 난 안 늘어난 거 아닌가 뭐 잘못한 듯

암튼. splitter2를 만들어보자 이번엔 recursive로!!

```
# split
from langchain_text_splitters import CharacterTextSplitter
from langchain_text_splitters import RecursiveCharacterTextSplitter
# 내용을 자를 땐 두 가지 splitter. CharacterTextSplitter와 RecursiveCharacterTextSplitter

text_splitter = CharacterTextSplitter(
    separator = '\m',
    chunk_size = 50, # 100자 단위로 잘라서 페이지를 쪼갬
    chunk_overlap = 5, # 10자씩 겹침(?)
    length_function = len
)

text_splitter2 = RecursiveCharacterTextSplitter(
    separators = '\m',
    chunk_size = 50,
    chunk_overlap = 5,
    length_function = len
)
```

```
texts = text_splitter.split_text(pages[45].page_content)
texts2 = text_splitter2.split_text(pages[45].page_content)

WARNING: langchain_text_splitters.base: Created a chunk of size 81, which is longer than the specified 50
```

• recursive로 하니까 warning이 안 뜸

```
char_list = []
for i in range(len(texts)):
    char_list.append(len(texts[i]))

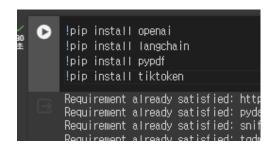
print(char_list)

char_list = []
for i in range(len(texts2)):
    char_list.append(len(texts2)):
    char_list.append(len(texts2[i]))

print(char_list)

[8, 80, 41, 37, 42, 37, 41, 40, 43, 39, 12, 40, 39, 42, 36, 40, 40, 39, 36, 38, 38, 38, 39, 40, 39, 49, 47]
[8, 82, 41, 37, 42, 37, 41, 40, 43, 39, 12, 40, 39, 42, 36, 40, 40, 39, 36, 38, 38, 38, 39, 40, 39, 34, 40, 20]
```

• 하지만 이건 별로임. 토큰 단위로 자르자



```
import tiktoken tokenizer = tiktoken.get_encoding('c1100k_base')
```

- "tokenizer": 토큰 단위로 잘라주는 객체
- 토크나이저 자르는 방식도 여러 가지. gpt4 방식이랑 gpt3 방식이 다름
- 토큰 세는 방식은 encoder에 의해 결정됨
- gpt4는 cl100k 써야함. 이게 표준처럼 쓰이는 중.

토큰의 개수를 셀 수 있는 함수를 만들어보자

```
[36] # 토큰의 개수를 세는 함수
def tiktoken_len(text):
    tokens = tokenizer.encode(text)
    print(tokens)
    return len(tokens)

tiktoken_len('| love you')

[40, 3021, 499]
3
```

- 토큰의 개수 3개 출력
- 다른 걸 길게 넣어도 잘
- 글자 수 ≥ 토큰 수

```
tiktoken_len('동해물과 백두산이')

[58189, 34983, 167, 105, 120, 54780, 22817, 109, 167, 80010, 86157, 13094]
12
```

• 한글은 무조건 토큰의 수가 많아짐 ⇒ 한글을 쓰면 토큰 소모가 심함 한글은 unicode를 쓰니까...

Tokenizer를 적용해서 split해보자

```
itext_splitter2 = RecursiveCharacterTextSplitter(
separators = '\m',
chunk_size = 50,
chunk_overlap = 5,
length_function = tiktoken_len # 이제부터 글자 단위가 아니라 토큰 단위로 쪼갬
```

```
[41] texts2 = text_splitter2,split_text(pages[45],page_content)

[2790, 765, 220, 220, 2618]
[199, 791, 12126, 32479, 315, 31480, 612, 24780, 38187, 35495, 33943, 254, 72208, 43139, 55216, 67945, 53400, 13447, 13, 5251, 199, 97472, 36982, 223, 19954, 49055, 41871, 225, 30381, 82068, 39823, 223, 169, 244, 98, 18359, 5251, 107, 116, 49072, 254, 199, 30426, 41953, 19954, 49065, 28833, 97196, 13, 29955, 161873, 52072, 264, 89, 293, 24486, 57519, 29954, 30426, 41953, 1995, 86811, 59189, 42189, 29383, 29779, 39331, 19094, 90195, 97, 17164, 230, 5251, 123, 238, 78553, 49958, 6945, 78424, 230, 22, 1996, 86811, 59189, 40189, 29383, 2779, 2799, 21028, 45618, 41953, 65651, 44966, 34004, 91556, 76242, 200, 22005, 55216, 166, 199, 14447, 24140, 30229, 13973, 227, 25799, 21028, 45618, 41953, 65651, 44966, 34004, 91556, 76242, 200, 22005, 55216, 166, 199, 71682, 58064, 230, 84136, 25944, 41847, 101, 59897, 116, 21028, 47932, 250, 30931, 57329) 19954, 49065, 46110, 101, 59189, 1996, 1996, 24140, 30229, 13973, 227, 25799, 21028, 45618, 41953, 65651, 44966, 34004, 91556, 76242, 2504, 2200, 22005, 55216, 166, 1996, 166, 55, 2344, 41881, 48956, 520464, 238, 40181, 48956, 520464, 238, 40181, 48956, 520464, 238, 40181, 48956, 520464, 238, 40181, 48956, 520464, 238, 40181, 48956, 520464, 238, 40181, 48956, 520464, 238, 40181, 48956, 520464, 238, 40181, 48956, 520464, 238, 40181, 97, 20128, 41936, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945, 41945
```

```
char_list = []
for i in range(len(texts2)):
    char_list.append(len(texts2[i]))

print(char_list)

[8, 80, 41, 37, 42, 37, 41, 40, 43, 39, 12, 40, 39, 42, 36, 40, 40, 39, 36, 38, 38, 39, 40, 39, 34, 40, 20]
```

https://colab.research.google.com/drive/1Zk4c4Yomu86KgUEla1J1NOF6J0wr6jyW?usp=sharing

https://colab.research.google.com/drive/1Zk4c4Yomu86KgUEla1J1NOF6J0wr6jyW?usp=sharing

<generative ai.txt 파일 다운로드 받자>

```
# Text file을 얼어서 내용을 가져온다.
with open('/content/generative ai.txt') as f:
    text_gen_ai = f.read()

[ ] !pip install langchain pypdf

Collecting langchain Downloading langchain-0.1.13-py3-none-any.whl (810 kB)

Collecting pypdf

Downloading pypdf-4.1.0-py3-none-any.whl (286 kB)

Requirement already satisfied: PyYAML>=5.3 in /usr/local/lib/python3.10/dist-packages (from langchain) (6.0.1)

Requirement already satisfied: SOLAlchemy<3.>=1.4 in /usr/local/lib/python3.10/dist-packages (from langchain) (2.0.29)
```

• 그냥 python 텍스트 코드 파일 & langchain과 pypdf 읽어서 가져오는 코드

- 문단 단위로 쪼개겠다 & \n:
- splitter를 만든 다음 text 파일 만들어서 잘라보겠다~ 했는데 하나가 오버된 걸 확인함

```
print(texts[0])
     print('-' * 100)
     print(texts[1])
    print('-' * 100)
print(texts[2])

    Generative artificial intelligence

     Talk
     Read
     Edit
     View history
     From Wikipedia, the free encyclopedia
     Not to be confused with Artificial general intelligence.
     A detailed oil painting of figures in a futuristic opera scene
    Théâtre D'opéra Spatial, an image generated by Midjourney
Generative artificial intelligence (generative Al, GenAl,[1] or GAl) is artificial intelligence capable of generating tex
     Improvements in transformer-based deep neural networks enabled an Al boom of generative Al systems in the early 2020s. Th
     Generative Al has uses across a wide range of industries, including software development, healthcare, finance, entertainm
     Main article: History of artificial intelligence
     The academic discipline of artificial intelligence was established at a research workshop held at Dartmouth College in 19
[ ] char_list = []
    for i in range(len(texts)):
       char_list.append(len(texts[i]))
     print(char_list)
[662, 974, 982, 861, 712, 783, 590, 820, 936, 982, 862, 968, 641, 830, 755, 894, 662, 812, 688, 648, 746, 788, 692, 425,
```

• // 텍스트 자르고 오버된 걸 확인

split document로 문서 객체를 만들어서 출력해보자

```
[] docs = text_splitter.split_documents(pages)

[] docs[2]

Document(page_content="& 약m: 지구 온단화로 인한 폭엽, 폭설, 태풍, 산불 등 이상기호 현상이 세계 곳곳에서 발생되고 있뻐는 가운데 기호 단소중립을 위한 목해,표와 전략을 수립하여 실천 중에 있음째·우리나라 전보 2020년 12월 7일 관계부처 합동으로 '2050 탄소중립 사용을 위한 목해,표와 전략을 수립하여 실천 중에 있음째·우리나고 지난 2020년 12월 7일 관계부처 합동으로 '2050 탄소중립 자상을 통시 달성하기 배위해 소경제구조 저탄소화 , 소저탄소 산업생태계 조성, 소탄소중립사회로의 공정전환의 3배대 정책방향과 소탄소중립 전현하빠,겠다는 의지를 표명합째·세계 각국은 2015년 12월 '파리기호변화합정' 채택 이전 국가온실가스감축목표를 바에 제뻐출했으며 , 2021년 표로 제출(2015년 6월)한 뒤, '2030 배국가 온실가스 감축 수정로드맵 (2018년 7월)'을 마련하고 '저탄소 녹색성장 기본법 시행배령'을 의에서 기존에 제뻐출한 국가온실가스감축목표를 추가 상향해 올해 안에 비에게 제출하겠다고 밝혀 더욱 도전빠적인 목표가 수립될 것으로 보임째 립 대용이 결교 쉬운 과제는 아닐 것임배·우리나라 중소기업들은 여전히 탄소중립에 대한 필요성을 크게 느끼지 못하고 있는 상태임m-최근 대유와 경험이 없기 때문에 대용에 한계를 보배이고 있음째- 많은 중소기업이 친환경 기술 및 제품 개발, 사업 전환 등에 적극적으로 참여한다 '/content/[정책브리프 2021-04] 탄소중립 대용을 위한 정부 정책과 동향 (1).pdf', 'page': 2})
```

- 일부러 문서 객체를 만드는 이유는 문서 객체를 만들 때 메타 데이터가 들어가기 때문
- 그래서 그냥 자르지 않고 굳이 문서 객체를 만들어서 자르는 것

```
[ ] # PDF 파일을 Split한다.

from langchain.document_loaders import PyPDFLoader

loader = PyPDFLoader('/content/대한상공회의소_탄소중립_미래전략_보고서_Part1 (1).pdf')
pages = loader.load_and_split()

[ ] # 홈 페이지 수
    print(len(pages))
    print(type(pages))
    print(type(pages)(0))
    print(pages[0].metadata)
    print(pages[0].metadata['source'])
    print(pages[0].metadata['page'])

19
    <class 'list'>
    <class 'list'>
    <class 'langchain_core.documents.base.Document'>
    {'source': '/content/[정책보리프 2021-04] 탄소중립 대응을 위한 정부 정책과 동향 (1).pdf', 'page': 0}
    /content/[정책보리프 2021-04] 탄소중립 대응을 위한 정부 정책과 동향 (1).pdf
0
```

- pdf 파일을 읽어들였는데 메타 데이터가 들어있음 (source: pdf 파일의 이름, page: 이 pdf
 의 몇 번째 페이지인지)
- pdf 파일로 정보를 만들어 return했을 때 원본 데이터가 뭔지 알고 싶을 때 메타 데이터를 이용 가능

```
[] docs[2]

Document(page_content="요 약m·지구 온난화로 인한 폭염, 폭설, 태풍, 산불 등 이상기후 현상이 세계 곳곳에서 발생되고 있는는 가운데 기후변화 단소중립을 위한 목등표와 전략을 수립하며 삼천 중에 있음★·우리나라 정부도 지난 2020년 12월 7일 관계부처 합동으로 '2050 단소중립 추진전략 상을 통시 달성하기 \\mathcal{m} 하하나 정책 보신 기후변화 상을 통시 달성하기 \\mathcal{m} 하하나 제계 각국은 2015년 12월 '마리 기후변화합정' 채택 이전 국가온실가스감축목표를 내에 제\\mathcal{m} 한 뒤, '2030 \\mathcal{m} 하국가 온실가스 감축 수정로드맵 (2018 년 7월)'을 마련하고 '저탄소 녹색성장 기본법 시행\\mathcal{m} 경 등 개정의에서 기존에 제\\mathcal{m} 기존실가스감축목표를 추가 상황해 올해 안에 내에 제출하겠다고 밝혀 더욱 도전\\mathcal{m} 지원 기존의 지문 기준 기존실가스감축목표를 수가 상황해 올해 안에 내에 제출하겠다고 밝혀 더욱 도전\\mathcal{m} 지원 기존의 지문 기준 기존 상태임하는 우리나라 중소기업들은 여전히 탄소중립에 대한 필요성을 크게 느끼지 못하고 있는 상태임짜 최근 대기 여유와 경험이 없기 때문에 대용에 한계를 보\\mathcal{m} 이유 함 경험이 없기 때문에 대용에 한계를 보\\mathcal{m} 이유 함 당해 당해 당해 당해 당한 경험이 원기 때문에 대용에 한계를 보\\mathcal{m} 이유 함 당한 경험이 없기 때문에 대용에 한계를 보\\mathcal{m} 이유 함 당한 경험 당취 당취 당취 당취 당취 당취 당취 기술 및 제품 개발, 사업 전환 등에 적극적으로 참여한다면 '/content/[정책보리프 2021-04] 탄소중립 대응을 위한 정부 정책과 동향 (1).pdf', 'page': 2})
```

• 위에서 가져온 pdf 파일을 다시 한번 split해서 세 번째 페이지 확인한 것

```
[ ] char_list = []
    for i in range(len(docs)):
        char_list.append(len(docs[i].page_content))
    print(char_list)
[175, 239, 1200, 1324, 1231, 1210, 1258, 1093, 1023, 840, 962, 823, 686, 855, 818, 823, 751, 366, 78]
```

• 여기서도 chunk size넘어가는 애들이 있음을 확인

recursive ~로 다시 한번 잘라보자

```
[6] from langchain.text_splitter import RecursiveCharacterTextSplitter
       text_splitter = RecursiveCharacterTextSplitter(
                              chunk_size=1000,
                                chunk_over!ap=100,
                                length_function=len
[ ] docs = text_splitter.create_documents([text_gen_ai])
[ ] print(len(docs))
print(len(docs[0].page_content))
print(docs[0].page_content)
print('-' * 100)
      print(docs[1].page_content)
print('-' * 100)
       print(docs[2].page_content)
      what is generative al.

Generative Al can learn from existing artifacts to generate new, realistic artifacts (at scale) that reflect the characteristics of the tr
Generative Al uses a number of techniques that continue to evolve. Foremost are Al foundation models, which are trained on a broad set of
       Today, generative Al most commonly creates content in response to natural language requests - it doesn't require knowledge of or entering
       What's behind the sudden hype about generative AI?
       what's behind the sudden hype about generative Air.
Gartner has tracked generative Al on its Hype Cycle™ for Artificial Intelligence since 2020 (also, generative Al was among our Top Strate
ChatGPT, launched by OpenAl, became wildly popular overnight and galvanized public attention. (OpenAl's DALL–E 2 tool similarly generate
      for i in range(len(docs)):
    char_list.append(len(docs[i].page_content))
       print(char_list)
       [673, 328, 659, 672, 904, 989, 925, 915, 927, 936, 370, 754, 915, 984, 858, 907, 356, 995, 374, 767, 851, 878, 791, 868, 934, 777, 669]
```

- 결과가 다르게 나오는 것을 확인. 1000자 넘는 게 없음
- ⇒ 우리가 원하는 사이즈대로 자르려면 recursive~을 이용하자!

<토큰 단위 텍스트 분할기>



- 영어가 많이 들어간 페이지: 글자 수 > 토큰 수 (?)
- 비용은 토큰 단위로 차감됨

• 11페이지 출력. 한글이니까 토큰으로 보면 좀 안 좋겠지ㅠ

• 학습시킬 땐 영어로 하자!

<이번엔 임베딩을 해보자>

https://colab.research.google.com/drive/1SuJuwEIOOHBqVJz3UH9J7cnpNpKXInY0?usp=sharing

필요한 라이브러리 설치하고 시작

```
||pip install openai langchain pypdf tiktoken
   Requirement already satisfied: openai in /usr/local/lib/python3.10/dist-packages (1.10.0)
   Requirement already satisfied: langchain in /usr/local/lib/python3.10/dist-packages (0.1.5)
  Requirement already satisfied: pypdf in /usr/local/lib/python3.10/dist-packages (4.0.1)
Requirement already satisfied: tiktoken in /usr/local/lib/python3.10/dist-packages (0.5.2)
Requirement already satisfied: anyio<5,>=3.5.0 in /usr/local/lib/python3.10/dist-packages (from openai) (3.7.1)
Requirement already satisfied: distro<2,>=1.7.0 in /usr/lib/python3/dist-packages (from openai) (1.7.0)
   Requirement already satisfied: httpx<1,>=0.23.0 in /usr/local/lib/python3.10/dist-packages (from openai) (0.26.0)
   Requirement already satisfied: pydantic<3,>=1.9.0 in /usr/local/lib/python3.10/dist-packages (from openai) (1.10.14)
Requirement already satisfied: sniffio in /usr/local/lib/python3.10/dist-packages (from openai) (1.3.0)
   Requirement already satisfied: tqdm>4 in /usr/local/lib/python3.10/dist-packages (from openai) (4.66.1)
   Requirement already satisfied: typing-extensions<5,>=4.7 in /usr/local/lib/python3.10/dist-packages (from openai) (4.9.0 Requirement already satisfied: PyVAML>=5.3 in /usr/local/lib/python3.10/dist-packages (from langchain) (6.0.1) Requirement already satisfied: SQLAIchemy<3,>=1.4 in /usr/local/lib/python3.10/dist-packages (from langchain) (2.0.24)
   Requirement already satisfied: aighttp<4.0.0,>=3.8.3 in /usr/local/lib/python3.10/dist-packages (from langchain) (3.9.3)
   Requirement already satisfied: async-timeout<5.0.0,>=4.0.0 in /usr/local/lib/python3.10/dist-packages (from langchain)
   Requirement already satisfied: dataclasses-json<0.7,>=0.5.7 in /usr/local/lib/python3.10/dist-packages (from langchain)
Requirement already satisfied: jsonpatch<2.0,>=1.33 in /usr/local/lib/python3.10/dist-packages (from langchain) (1.33)
   Requirement already satisfied: langchain-community<0.1,>=0.0.17 in /usr/local/lib/python3.10/dist-packages (from langcha Requirement already satisfied: langchain-core<0.2,>=0.1.16 in /usr/local/lib/python3.10/dist-packages (from langchain) (
   Requirement already satisfied: langsmith<0.1,>=0.0.83 in /usr/local/lib/python3.10/dist-packages (from langchain) (0.0.85
Requirement already satisfied: numpy<2,>=1 in /usr/local/lib/python3.10/dist-packages (from langchain) (1.23.5)
Requirement already satisfied: requests<3,>=2 in /usr/local/lib/python3.10/dist-packages (from langchain) (2.31.0)
   Requirement already satisfied: tenacity<9.0.0,>=8.1.0 in /usr/local/lib/python3.10/dist-packages (from langchain) (8.2.3 Requirement already satisfied: regex>=2022.1.18 in /usr/local/lib/python3.10/dist-packages (from tiktoken) (2023.6.3)
   Requirement already satisfied: aiosignal>=1.1.2 in /usr/local/lib/python3.10/dist-packages (from aiohttp<4.0.0,>=3.8.3-> Requirement already satisfied: attrs>=17.3.0 in /usr/local/lib/python3.10/dist-packages (from aiohttp<4.0.0,>=3.8.3->lan
   Requirement already satisfied: frozenlist>=1.1.1 in /usr/local/lib/python3.10/dist-packages (from alohttp<4.0.0,>=3.8.3-
Requirement already satisfied: multidict<7.0,>=4.5 in /usr/local/lib/python3.10/dist-packages (from alohttp<4.0.0,>=3.8.
   Requirement already satisfied: warl<2.0,>=1.0 in /usr/local/lib/python3.10/dist-packages (from alohttp<4.0.0,>=3.8.3->lar
Requirement already satisfied: idna>=2.8 in /usr/local/lib/python3.10/dist-packages (from anyio<5,>=3.5.0->openai) (3.6)
   Requirement already satisfied: exceptiongroup in /usr/local/lib/python3.10/dist-packages (from anylo<5,>=3.5.0->openai)
Requirement already satisfied: marshmallow<4.0.0,>=3.18.0 in /usr/local/lib/python3.10/dist-packages (from dataclasses-
   Requirement already satisfied: typing-inspect<1,>=0.4.0 in /usr/local/lib/python3.10/dist-packages (from dataclasses-js Requirement already satisfied: certifi in /usr/local/lib/python3.10/dist-packages (from httpx<1,>=0.23.0->openai) (2023
```

```
[ ] import os

os.environ['OPENAI_API_KEY'] = 'bb6860ae08e147eeae418efdce560e4e'
os.environ['AZURE_OPENAI_ENDPOINT'] = 'https://helloai-openai-025.openai.azure.com/'
os.environ['OPENAI_API_TYPE'] = 'azure'
os.environ['OPENAI_API_YERSION'] = '2023-05-15'
```

임베딩 = 데이터를 데이터 체계로 바꾼다 일반적으론 수치로 바꾼다.. 언어 모델에서의 임베딩... 단어들 사이의 좌표 관계 사람과 바나나가 가까운지 원숭이와 바나나가 가까운지 언어마다 거리감이 달라서 임베딩하는 모델이 다 다름 한국어, 영어 등등 다 다름 작은 걸 쓸 땐 임베딩이 안 맞음 openAI처럼 돈 많은 곳 전용 암튼 임베딩-ada-002 배포

일반적인 language 모델에 비해 임베딩 모델은 상대적으로 난이도가 많이 떨어짐 일단 이걸로 하겠지만 오픈소스 기반의 LLM 사용하는 것도 이따가 볼 것

• Azure에서 내부적으로 임베딩 모델 랩핑해놓은 애를 가져옴

이제 단어 말고 문장 위주로 보자

```
embedded_query_q = embeddings_model.embed_query('이 대화에서 언급된 이름은 무엇입니까?')
embedded_query_a = embeddings_model.embed_query('이 대화에서 언급된 이름은 홍길동 입니다.')

WARNING:langchain_community.embeddings.openai:Warning: model not found. Using cl100k_base encoding.
WARNING:langchain_community.embeddings.openai:Warning: model not found. Using cl100k_base encoding.

[ ] len(embedded_query_q)

1536
```

- 다섯 개가 임베딩돼서 들어감
- 0번에 1536차원, 1번에 1536차원, ... : 각각의 문장을 임베딩할 때 각각의 데이터가 1536차 원으로 임베딩된다는 것. 임베딩 모델이 클수록 차원 수가 많아지고, 차원 수가 많아지면 더 정확하게 분류 가능.
- 대신 차원 수를 늘릴 땐 데이터 수도 함꼐 늘려줘야 한다는 것. GPU 비용도 고려해야 함.

- cl100k_base: GPT3.5 이상에서 쓰고 있는 encoding 방법
- 암튼 이렇게 encoding해도 각각의 문장은 1536차원으로 인코딩되어 있다는 것

```
#벡터의 거리를 측정하는 cos_sim()를 만든다.
from numpy import dot
from numpy.linalg import norm
import numpy as np

def cos_sim(A,B):
    distance = dot(A,B) / (norm(A)*norm(B))
    return distance

print(cos_sim(embedded_query_q, embedded_query_a))
    print(cos_sim(embedded_query_q, embedding_result[1]))
    print(cos_sim(embedded_query_q, embedding_result[3]))

0.9070222021812047
0.7762442819388633
0.7316183027788279
```

- 2차원 좌표 거리 측정... 두 단어의 유사도를 측정하기 위해 거리를 측정하는 함수를 만들기
- dot 연산을 하자! cos simulator 기법으로. 가장 기본적인 방법.
- 각 좌표 사이의 거리로 유사도를 알 수 있음
- 1에서 멀어지면 멀어질수록 유사도가 낮아짐
- // 이걸 왜 이렇게 할까?
 - 。 페이지 수 엄청 많은 파일에서 뭔가를 찾으려고 할 때
 - 。 차원으로 바꾼 다음 벡터 기반으로 검색하면
 - 。 성능에 비해 비용이 거의 안 듦
 - 。 그래서 이걸 벡터 DB화 시키는 것

<HuggingFace> LLM계의 오픈소스

- huggingface에 있는 모델을 여기서 바로 다운 받고 사용 가능
- 모델명만 알면 됨

Huggingface Embedding

- !pip install sentence_transformers
- Requirement already satisfied: sentence_transformers in /usr/local/lib/python3.10/dist-packages (2.3.1) Requirement already satisfied: transformers<5.0.0,>=4.32.0 in /usr/local/lib/python3.10/dist-packages (from sentence_transformers) (4.66. Requirement already satisfied: tqdm in /usr/local/lib/python3.10/dist-packages (from sentence_transformers) (4.66. Requirement already satisfied: torch>=1.11.0 in /usr/local/lib/python3.10/dist-packages (from sentence_transformers) (4.23 Requirement already satisfied: numpy in /usr/local/lib/python3.10/dist-packages (from sentence_transformers) (1.23 Requirement already satisfied: numpy in /usr/local/lib/python3.10/dist-packages (from sentence_transformers) (1.23 Requirement already satisfied: numpy in /usr/local/lib/python3.10/dist-packages (from sentence_transformers) (1.23 Requirement already satisfied: numpy in /usr/local/lib/python3.10/dist-packages (from sentence_transformers) (1.23 Requirement already satisfied: numpy in /usr/local/lib/python3.10/dist-packages (from sentence_transformers) (1.23 Requirement already satisfied: numpy in /usr/local/lib/python3.10/dist-packages (from sentence_transformers) (1.23 Requirement already satisfied: numpy in /usr/local/lib/python3.10/dist-packages (from sentence_transformers) (1.23 Requirement already satisfied: numpy in /usr/local/lib/python3.10/dist-packages (from sentence_transformers) (1.23 Requirement already satisfied: numpy in /usr/local/lib/python3.10/dist-packages (from sentence_transformers) (1.23 Requirement already satisfied: numpy in /usr/local/lib/python3.10/dist-packages (from sentence_transformers) (1.23 Requirement already satisfied: numpy in /usr/local/lib/python3.10/dist-packages (from sentence_transformers) (1.23 Requirement already satisfied: numpy in /usr/local/lib/python3.10/dist-packages (from sentence_transformers) (1.23 Requirement already satisfied: numpy in /usr/local/lib/python3.10/dist-packages (from sentence_transformers) (1.23 Requirement already satisfied: numpy in /usr/local/lib/python3.10/dist-packages (from sentence_transformers) (1.23 Requirement already satisfied: numpy in /usr/local/lib/pytho Requirement already satisfied: scikit-learn in /usr/local/lib/python3.10/dist-packages (from sentence_transformers) (1.1 Requirement already satisfied: scipy in /usr/local/lib/python3.10/dist-packages (from sentence_transformers) (1.1) Requirement already satisfied: nltk in /usr/local/lib/python3.10/dist-packages (from sentence_transformers) (3.8.1 Requirement already satisfied: sentencepiece in /usr/local/lib/python3.10/dist-packages (from sentence_transformers) Requirement already satisfied: huggingface-hub>=0.15.1 in /usr/local/lib/python3.10/dist-packages (from sentence_ Requirement already satisfied: Pillow in /usr/local/lib/python3.10/dist-packages (from sentence_transformers) (9.4 Requirement already satisfied: filelock in /usr/local/lib/python3.10/dist-packages (from huggingface-hub>=0.15.1-Requirement already satisfied: fsspec>=2023.5.0 in /usr/local/lib/python3.10/dist-packages (from huggingface-hub> Requirement already satisfied: requests in /usr/local/lib/python3.10/dist-packages (from huggingface-hub>=0.15.1-Requirement already satisfied: pyyaml>=5.1 in /usr/local/lib/python3.10/dist-packages (from huggingface-hub>=0.15. Requirement already satisfied: typing-extensions>=3.7.4.3 in /usr/local/lib/python3.10/dist-packages (from huggingface-hub>=0.15. Requirement already satisfied: packaging>=20.9 in /usr/local/lib/python3.10/dist-packages (from huggingface-hub>= Requirement already satisfied: sympy in /usr/local/lib/python3.10/dist-packages (from torch>=1.11.0->sentence_tran Requirement already satisfied: networkx in /usr/local/lib/python3.10/dist-packages (from torch>=1.11.0->sentence_t Requirement already satisfied: jinja2 in /usr/local/lib/python3.10/dist-packages (from torch>=1.11.0->sentence_tra Requirement already satisfied: triton==2.1.0 in /usr/local/lib/python3.10/dist-packages (from torch>=1.11.0->sente Requirement already satisfied: regex!=2019.12.17 in /usr/local/lib/python3.10/dist-packages (from transformers<5.0 Requirement already satisfied: tokenizers<0.19,>=0.14 in /usr/local/lib/python3.10/dist-packages (from transformer Requirement already satisfied: safetensors>=0.3.1 in /usr/local/lib/python3.10/dist-packages (from transformers<5. Requirement already satisfied: click in /usr/local/lib/python3.10/dist-packages (from nltk->sentence_transformers) Requirement already satisfied: joblib in /usr/local/lib/python3.10/dist-packages (from nltk->sentence_transformers Requirement already satisfied: threadpoolctl>=2.0.0 in /usr/local/lib/python3.10/dist-packages (from scikit-learn-Requirement already satisfied: MarkupSafe>=2.0 in /usr/local/lib/python3.10/dist-packages (from jinja2->torch>=1.1 Requirement already satisfied: charset-normalizer<4,>=2 in /usr/local/lib/python3.10/dist-packages (from requests-Requirement already satisfied: idna<4,>=2.5 in /usr/local/lib/python3.10/dist-packages (from requests->huggingface Requirement already satisfied: urllib3<3,>=1.21.1 in /usr/local/lib/python3.10/dist-packages (from requests->huggingface Requirement already satisfied: certifi>=2017.4.17 in /usr/local/lib/python3.10/dist-packages (from requests->huggingface Requirement already satisfied: certifi>=2017.4.17 in /usr/local/lib/python3.10/dist-packages (from requests->huggingface
- 이것도 써봤다고 하는 게 좋은~
- sentence_transformers: huggingface에 있는 모델을 사용할 때 쓰는 패키지명
- 참고로... language 모델은 운영할 때도 gpu가 많이 듦
- huggingface에 있는 모델들은 잘만 튜닝하면 cpu만으로도 실행 가능하다는 장점...

- 모델명, 활동명, 영어만 가능한 모델..
- 모델에 대한 설정.. GPU/CPU에서 돌아가게끔
- HuggingFaceEmbeddings: huggingFace에서 실제로 모델을 가져오는 명령

```
► from Tangchain.embeddings import HuggingFaceBgeEmbeddings
      model_name = 'BAAI/bge-small-en'
      model_kwargs = {'device':'cpu'}
encode_kwargs = {'normalize_embeddings':True}
      hf = HuggingFaceBgeEmbeddings(
                model_name = model_name,
                model_kwargs = model_kwargs,
                encode_kwargs = encode_kwargs
/usr/local/lib/python3.10/dist-packages/huggingface_hub/utils/_token.py:88: UserWarning:
The secret `HF_TOKEN` does not exist in your Colab secrets.
      To authenticate with the Hugging Face Hub, create a token in your settings tab (<a href="https://huggingface.co/settings/tokens">https://huggingface.co/settings/tokens</a>), set it You will be able to reuse this secret in all of your notebooks.
      Please note that authentication is recommended but still optional to access public models or datasets.
        warnings.warn(
      modules.json: 100%
                                                                                349/349 [00:00<00:00, 13.8kB/s]
      config_sentence_transformers.json: 100%
                                                                                                  124/124 [00:00<00:00, 5.37kB/s]
      README.md: 100%
                                                                               90.8k/90.8k [00:00<00:00, 1.73MB/s]
      sentence_bert_config.json: 100%
                                                                                           52.0/52.0 [00:00<00:00, 3.11kB/s]
      config.json: 100%
                                                                             684/684 [00:00<00:00, 38.2kB/s]
      model.safetensors: 100%
                                                                                    133M/133M [00:01<00:00, 96.6MB/s]
      tokenizer_config.json: 100%
                                                                                       366/366 [00:00<00:00, 14.5kB/s]
      vocab.txt: 100%
                                                                            232k/232k [00:00<00:00, 3.55MB/s]
                                                                               711k/711k [00:00<00:00, 10.6MB/s]
      tokenizer.json: 100%
      special_tokens_map.json: 100%
                                                                                          125/125 [00:00<00:00, 4.55kB/s]
      1_Pooling/config.json: 100%
                                                                                        190/190 [00:00<00:00, 8.43kB/s]
```

• 이런 식으로 출력됨

• 흠... 뭐라 하셨는지 까먹음

```
[ ] BGE_query_q = hf.embed_query('Hello? who is this?')
    BGE_query_a = hf.embed_query('hi this is harrison?')

[ ] print(cos_sim(BGE_query_q, BGE_query_a))
    print(cos_sim(BGE_query_q, emdedding_result[1]))
    print(cos_sim(BGE_query_q, emdedding_result[5]))

    0.8585610628040985
    0.7469068511786857
    0.792870425931663
```

- 아까랑 똑같이 두 개를 만들어 비교해보기
- 유사도 85%... 1번 5번 둘 다 딴소리니까 0.78 정도에서 그침
- 보통 80% 넘어가면 어느 정도 맞다고 봄

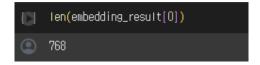
한글 무료로 쓰려면...

<ko-sbert-nli> 한글로 튜닝해서 만들어 놓은 것

```
ko-sbert-nli
model_name = 'jhgan/ko-sbert-nli'
model_kwargs = {'device':'cpu'}
encode_kwargs = {'normalize_embeddings':True}
hf = HuggingFaceBgeEmbeddings(
           model_name = model_name,
           model_kwargs = model_kwargs,
           encode_kwargs = encode_kwargs
      modules.json: 100%
                                                                              229/229 [00:00<00:00, 3.93kB/s]
                                                                                                  123/123 [00:00<00:00, 3.45kB/s]
      config_sentence_transformers.json: 100%
      README.md: 100%
                                                                             4.46k/4.46k [00:00<00:00, 288kB/s]
      sentence_bert_config.json: 100%
                                                                                         53.0/53.0 [00:00<00:00, 3.02kB/s]
      config.json: 100%
                                                                            620/620 [00:00<00:00, 34.8kB/s]
      pytorch_model.bin: 100%
                                                                                   443M/443M [00:05<00:00, 121MB/s]
      tokenizer_config.json: 100%
                                                                                     538/538 [00:00<00:00, 18.0kB/s]
      vocab.txt: 100%
                                                                          248k/248k [00:00<00:00, 4.08MB/s]
      tokenizer.json: 100%
                                                                              495k/495k [00:00<00:00, 8.86MB/s]
      special_tokens_map.json: 100%
                                                                                        112/112 [00:00<00:00, 7.32kB/s]
                                                                                      190/190 [00:00<00:00, 8.15kB/s]
       1_Pooling/config.json: 100%
```

```
sentence = [
         '안녕하세요',
         '제 이름은 홍길동 입니다.',
        '이름이 무엇인가요?',
         '랭체인은 유용합니다.
         '홍길동 아버지의 이름은 홍상직 입니다. '
    embedding_result = hf.embed_documents(sentence)
[] q = '홍길동은 아버지를 아버지라 부르지 못해하였습니다. 홍길동 아버지의 이름은 무엇입니까?'
a = '홍길동의 아버지는 엄했습니다.'
    ko_query_q = hf.embed_query(q)
    ko_query_a = hf.embed_query(a)
[ ] print(cos_sim(ko_query_q, ko_query_a))
    print(cos_sim(ko_query_q, embedding_result[1]))
    print(cos_sim(ko_query_q, embedding_result[3]))
    print(cos_sim(ko_query_q, embedding_result[4]))
    0.8412900341366036
    0.5585852341123605
0.24146539720456686
    0.626779213871763
```

- 각각 비교했더니 유사도가 위와 같이 나옴
- langchain 부분은 유사도가 0.24로 확실히 낮음
- 암튼 이렇게 무료로 쓸 수 있는 임베딩 모델이 있다는 것...
- 임베딩할 땐 무료 모델을 쓰고 질문할 땐 chat gpt를 쓰면 비용 줄일 수 있음



- 768차원...
- 나중에 이걸 써보기 대신 ada를 사용하면 좀 더 결과 잘 나오긴 함